

# 案例与练习补充

## LLM Inference Infrastructure - 2026

这份材料不是独立专题，而是给各讲穿插使用的案例库。

BidKV、benchmark 异常、prefix reuse 和异构后端适配都会作为例子嵌入课程概念中。

后续新的论文、开源 PR、实验发现和学生项目也可以继续追加到这份材料。

### 当前收录的例子

- KV 压力与调度策略
- benchmark 折线与实验可信度
- prefix reuse 与状态一致性
- 异构后端适配与开源 PR 闭环

## 使用方式

这份材料不是独立专题，而是给各讲穿插使用的案例库。每个例子都可以放进对应章节，用来帮助学生把课程概念和真实系统问题连起来。后续如果有新的论文、开源 PR、benchmark 发现或系统调优经验，也可以继续追加到这里。

## 例子一：KV 压力为什么会改变调度策略

对应章节：第 4 讲 请求调度；第 5 讲 KV 缓存。

在普通连续批处理中，请求调度常被讲成“谁进入 batch、谁等待下一轮”。但在长上下文和高并发场景里，请求已经占用的 KV cache 也是重要状态。一个请求被暂停后，系统可能需要保留 KV、迁移 KV，或者重新 prefill，这些代价并不相同。

可以用 BidKV: Utility-Guided Preemption Scheduling for KV-Pressure LLM Serving (SC 2026) 作为课堂例子：当 KV cache 成为紧张资源时，调度器不只是判断“哪个请求先跑”，还要判断“哪个请求的状态更值得保留”。这能引出 utility、preemption cost、tail latency 和 throughput 之间的权衡。

课堂练习：给定 6 个请求的输入长度、已生成 token 数、KV block 占用和预计剩余输出长度，让学生分别用 FIFO、最大 KV 占用优先抢占、最短剩余时间优先和 utility-guided 策略做一次手工调度，并比较重算成本。

## 例子二：同一条性能折线为什么不能直接下结论

对应章节：第 2 讲 工作负载与评价指标；第 10 讲 论文比较方法；第 11 讲 实验方法与验证。

在 vLLM-HUST benchmark 中，折线图看起来很直观，但如果实验条件没有对齐，很容易把参数变化误判成系统优化或性能退化。

需要检查的条件包括：

- workload 是否一致，例如 random、ShareGPT、agent、code、vision、throughput 和 latency 模式不能混在一起比较。
- 模型是否一致，例如 dense、MoE、VL、INT8 和 FP16 不能只看名字相近。
- 硬件是否一致，例如 910B2、910B3、多卡拓扑和驱动栈必须明确标注。
- 参数是否一致，例如 input/output token size、concurrency、max-num-seqs、max-model-len、block size、enforce-eager 等都会改变结果。
- baseline 是否一致。比较 vLLM-HUST PR 时，应和同一条件下的 vLLM / vLLM-Ascend baseline 对比，而不是混用两个历史优化版本。

课堂练习：给学生一组折线图和 JSON metadata，让他们标出哪些点可以比较，哪些点必须补 baseline，哪些点可能是参数不一致导致的异常。

## 例子三：Prefix reuse 不是“缓存命中率”那么简单

对应章节：第 5 讲 KV 缓存；第 6 讲 状态管理与记忆组织；第 7 讲 推理系统架构。

代码生成、文档问答、agent-research 和多轮对话经常共享 system prompt、文档上下文或历史对话。prefix reuse 可以减少重复 prefill，但它也会引入新的系统问题：prefix 如何组织、如何淘汰、如何跨请求复用、如何保证状态一致。

可以让学生比较三种负载：

- 所有请求完全随机，没有共享 prefix。
- 所有请求共享 system prompt，但用户输入不同。
- 请求共享 system prompt 和长文档上下文，但输出长度差异很大。

课堂练习：设计一个简单 prefix tree，记录每个节点的引用计数、KV block 数和最近访问时间。让学生实现两种淘汰策略，并观察 TTFT 和 memory pressure 的变化。

## 例子四：异构后端适配为什么会影响实验可信度

对应章节：第 8 讲 执行优化与异构路径；第 9 讲 异构平台适配；第 12 讲 开源系统实践。

在 Ascend / NPU 后端上，性能不只取决于模型和 batch。runtime 版本、torch-npu pin、CANN、attention backend、graph capture、kernel fallback、通信拓扑都会影响结果。

这个例子可以帮助学生理解：开源系统适配不是“让代码跑起来”就结束，还要让 benchmark、CI 和环境记录能解释性能变化。

课堂练习：给定两次实验的依赖列表和启动参数，让学生判断哪一次结果更适合写进性能报告，哪些信息缺失会让结论不可复现。

## 例子五：从开源 PR 看研究工程闭环

对应章节：第 12 讲 开源系统实践；第 13 讲 课程项目工作坊。

真实系统工作常常从一个小 PR 开始：修 CI、补 benchmark、统一参数、修复某个 workload 的回归、把局部优化抽成可复用 patch。课程里可以把这些 PR 当作研究工程闭环的例子，而不只把论文当作最终成果。

一个合格的课程项目 PR 至少应该说明：

- 它修改了哪个系统路径。
- 它如何被测试。
- 它和 baseline 的比较条件是什么。
- 如果性能变化明显，原因是否能被日志、profile 或 metadata 支持。
- 如果只是工程修复，它如何提升后续实验的可复现性。

课堂练习：让学生阅读一个真实 PR，补齐“动机、修改点、测试、风险、后续实验”五段说明。

## 后续追加建议

后续课程中可以继续加入这些类型的例子：

- 新的 vLLM-HUST / vLLM-Ascend-HUST 优化 PR。
- 官方上游接收的修复或功能改进。
- 真实 benchmark 中发现的异常点和补数过程。
- 新论文中的调度、缓存、内存管理或异构执行设计。
- 学生课程项目中形成的可复现实验片段。